

[引用格式] 张俊, 罗凡, 袁政. 基于轻量化多尺度 CNN 的水下图像增强算法及边缘端部署 [J]. 水下无人系统学报, 2025, 33(6): 1065-1073.

基于轻量化多尺度 CNN 的水下图像增强算法 及边缘端部署

张 俊¹, 罗 凡², 袁 政¹

(1. 中国电子科技集团公司第五十八研究所, 江苏 无锡, 214035; 2. 武汉第二船舶设计研究所, 湖北 武汉, 430000)

摘 要: 针对水下可见光图像因水体散射、吸收导致的噪声干扰、纹理模糊、颜色失真问题, 以及传统增强算法计算量大且基本耗时长缺陷, 文中提出一种基于轻量化多尺度卷积神经网络(CNN)的水下图像增强算法。该算法采用 U-Net 结构, 融合浅层纹理特征与深层语义特征, 有效恢复图像纹理细节与颜色信息; 引入轻量化特征提取模块, 在精简模型参数的同时加快网络收敛速度; 在主干网络中嵌入多尺度金字塔池化, 强化多尺度特征提取能力, 弥补传统算法细节恢复不足的短板; 采用 L1 损失与结构相似性损失联合优化, 提升图像亮度与对比度的恢复效果。为满足工程应用低延时需求, 算法经量化后部署于嵌入式平台, 通过调用嵌入式神经网络处理器资源加速推理, 在 Atlas200IA2 上的前向推理耗时仅 28 ms。公开水下数据集的实验结果表明, 该算法在测试集上的水下图像质量度量与水下彩色图像质量评估指标分别达到 4.33 和 0.63, 验证了其增强效果的有效性。

关键词: 水下图像增强; 多尺度卷积神经网络; 轻量化; U-Net 结构; 边缘端部署

中图分类号: TJ630; U67

文献标识码: A

文章编号: 2096-3920(2025)06-1065-09

DOI: 10.11993/j.issn.2096-3920.2025-0094

Lightweight Multi-Scale CNN-Based Underwater Image Enhancement Algorithm and Edge Deployment

ZHANG Jun¹, LUO Fan², YUAN Zheng¹

(1. The 58th Research Institute of China Electronics Technology Group Corporation, Wuxi 214035, China; 2. Wuhan Second Ship Design and Research Institute, Wuhan 430000, China)

Abstract: This paper proposed a lightweight multi-scale convolutional neural network(CNN)-based underwater image enhancement algorithm to address the problems of noise interference, texture blur, color distortion, and high computational complexity and long time consumption of traditional enhancement algorithms caused by water scattering and absorption in underwater visible light images. The U-Net structure was used, which combined shallow texture features with deep semantic features to effectively restore the texture and color information of the image. A lightweight feature extraction module was introduced, which not only simplified the model parameters but also accelerated the convergence speed of the network. A multi-scale pyramid pooling was embedded in the backbone network for extracting multi-scale features and compensating for the shortcomings of traditional algorithms in detail restoration. By combining L1 loss with structural similarity index loss for joint optimization, the restoration effect of image brightness and contrast was improved. To meet the low latency requirements of engineering applications, the algorithm was quantized and then deployed on an embedded platform. By calling the embedded neural processing unit resources to accelerate the inference process, the forward inference on the Atlas200IA2 took

收稿日期: 2025-07-25; 修回日期: 2025-08-27; 录用日期: 2025-09-01.

作者简介: 张 俊(1995-), 男, 硕士, 工程师, 主要研究方向为目标检测与图像增强.

OPEN ACCESS

only 28 ms. Through experiments on publicly available underwater datasets, the algorithm proposed in this paper achieved an underwater image quality measure of 4.33 and the underwater color image quality evaluation index of 0.63, respectively, on the test set, demonstrating the effectiveness of the proposed enhancement algorithm.

Keywords: underwater image enhancement; multi-scale convolutional neural network; light weight; U-Net structure; edge deployment

0 引言

地球表面大部分区域被水体覆盖,水环境在国防军事及生态环境等领域的研究中具有重要意义。图像直观易懂的特性使其在海底地质地貌信息获取、海底军事目标搜寻以及海底隧道勘探等多个场景中被应用广泛。但水下环境复杂,散射作用会缩短成像距离,水体及水下物质还会吸收光线,这使得水下可见光图像普遍存在纹理模糊及颜色失真等问题。

针对水下可见光图像退化问题,当前主流图像增强算法可划分为传统算法与基于深度学习的算法两大类。传统增强算法以经典信号处理理论为核心,主要包括直方图均衡化、同态滤波及基于超拉普拉斯反射先验的水下图像增强算法(Retinex)等。直方图均衡化类方法通过扩展图像灰度动态范围提升全局对比度,其原理简洁且计算流程易于实现,但在增强过程中易放大噪声成分,导致图像细节信息丢失;同态滤波类方法将图像分解为光照分量与反射分量,通过针对性处理反射分量强化细节特征,然而该方法存在计算复杂度较高的问题,且无法有效修复水下图像的颜色失真;Retinex 算法基于“图像=亮度分量 $\times$ 颜色分量”的分解模型,通过对亮度分量进行拉伸变换改善对比度,可有效缓解水下图像的颜色失真与光照不均现象,但易引入光晕伪影,且整体计算开销较大,难以满足实时处理需求。

基于深度学习的增强算法依托数据驱动范式,通过模型训练学习图像退化与复原的映射关系,主流方法涵盖卷积神经网络(convolutional neural network, CNN)、生成对抗网络(generative adversarial network, GAN)及 Transformer 等。CNN 方法借助强大的局部特征提取能力,可高效学习低质量图像与高质量图像间的非线性映射关系,增强效果稳定性强,但对成对训练数据的规模与质量要求

较高;GAN 算法通过生成器与判别器的对抗训练机制,无需成对数据即可生成符合真实场景的高质量图像,数据适应性更强,然而其训练过程耗时较长,且在细节恢复的精准度上存在局限;Transformer 算法基于多头注意力机制捕获图像全局特征依赖,在颜色信息还原与细节保真度方面表现优异,但网络参数规模庞大,导致前向推理速度较慢,难以适配实时性应用场景。

针对以上问题,王永鑫等^[1]提出一种基于同态滤波的水下图像增强与色彩校正模型,通过结合比尔-朗伯定律和路径辐射分量构建出水下成像模型,通过麦克劳林级数对水下模型进行展开从而推导出保持水下图像色彩校正模型。李黎等^[2]提出基于改进暗原色先验和颜色校正的水下图像增强算法,通过改进水下暗原色先验法去除后向散射光,对处理后的图像使用白平衡算法进行颜色校正。杨润等^[3]提出一种基于颜色校正和暗亮双通道先验的水下图像增强算法,通过标准差比进行颜色恢复,通过滤波实现图像锐化后进行通道差异加权的暗亮双通道算法去除图像模糊,最后用多尺度融合方法将对比度增强图像和可见度恢复图像进行融合。王燕等^[4]提出一种基于注意力机制与特征重建的水下图像增强算法,通过残差模型融合注意力机制构建像素增强模型,同时利用边缘差分模块增强模型对边缘的关注度,以此恢复图像细节。程竹明等^[5]提出基于多分支残差注意力网络的水下图像增强算法,在编码与解码阶段加入色彩增强模块,在网络最后加入特征注意力机制加强关键特征提取能力,以此来恢复图像细节。王树林等^[6]提出一种基于双通道的水下图像增强卷积神经网络算法,一支通道通过稠密连接和特征注意力机制提取细节特征,另一支通道提取多尺度语义特征,两支通道特征融合后得到高质量图像。

综合上述算法分析可知,传统增强算法普遍存

在计算复杂度高、易引入噪声伪影等问题;而现有基于深度学习的算法未能充分利用多尺度特征,导致图像细节恢复不充分^[7],且普遍存在参数量庞大、难以满足实时处理需求的缺陷。为此,文中提出一种基于多尺度 CNN 的水下图像增强算法,采用 U-Net 网络结构,将浅层纹理特征与深层语义特征有机融合,在有效恢复图像颜色信息、改善整体质量的同时,避免引入额外噪声;其次引入轻量化特征提取模块,在减少模型参数量的基础上,既能降低前向推理耗时,又能加速网络收敛速度;在主干网络中嵌入多尺度金字塔池化模块,强化多尺度特征的提取能力,弥补传统网络特征表达丰富度不足的短板,实现图像纹理细节的精准恢复;最后采用 L_1 损失与结构相似性(structural similarity, SSIM)损失联合优化策略,针对性改善网络对图像亮度与对比度的恢复效果,提升增强后图像的视觉一致性。

1 网络框架

文中所提的水下可见光图像增强网络框架如图 1 所示,整体采用 U-Net 结构,包含特征提取模块(feature extraction module, FEM)、多尺度金字塔池化特征(multi-scale spatial pyramid pooling features, MSPPF)模块、通道注意力模块(channel attention module, CAM)以及特征融合模块(feature fusion module, FFM)4 个主要模块。

由图 1 可以看出,整个网络模型分为编码和解码两部分。编码包含 4 个 FEM 模块和 4 个 MSPPF 模块, FEM 模块仅负责特征提取,不执行降采样操作,确保浅层纹理特征的完整保留;特征图经 MSPPF 模块处理后,尺寸降采样至输入的 1/2,同时聚合多尺度语义特征。解码包含 4 个 FEM 模块和 1 个 FFM 模块,每个 FEM 模块后均设置 1 个上采样层,上采样后的特征与编码阶段对应的浅层特征进行元素相加,实现跨尺度特征融合,提升特征表达的丰富度。最终,汇总后的多尺度融合特征经 FFM 模块进一步整合优化,输出增强后的目标图像。

1.1 FEM

FEM 模块在目标检测、图像分割及目标跟踪等多个领域有着广泛的使用,主要用来提取目标的特征,但经典的 FEM 如采用牛津大学视觉几何组提出的




图 1 网络框架图

Fig. 1 Network framework diagram

卷积神经网络架构 VGG(visual geometry group)^[8]、ResNet(residual network)^[9]、Darknet^[10] 等网络层数多、计算量大,没有选择性地有效特征传递。文中提出一种轻量化 FEM,其网络结构如图 2 所示。图中: Conv 表示卷积模块; H 、 W 和 C 分别代表特征图的高度、宽度和通道数; Split 表示通道分离; Bottleneck 表示瓶颈结构; Concat 表示连接; Instance Norm 表示归一化; SiLU 表示激活函数。

由图 2 可知, FEM 模块的设计主要采用了通道分离和残差连接技术^[11],通道分离一方面保留原始的特征来增强信息的传递,另一方面与部分通道卷积后的结果进行连接可以融合不同尺度的特征;残差连接则是为了增加特征的丰富度和加强反向传播时梯度信息的传递,减少梯度消失的风险,加快模型收敛。FEM 模块均采用卷积核大小为 3×3 、步长为 1 的卷积操作。未使用通道分离时,其参数量为 $72C^2$;引入通道分离技术后,参数量降至 $31.5C^2$,参数量减少约 56%,充分验证了该




图 2 FEM 模块结构示意图

Fig. 2 Schematic diagram of the FEM module

轻量化特征提取模块在精简主干网络参数量方面的有效性。与 VGG 网络相比,后者仅通过 3×3 卷积层堆叠扩大感受野以提取特征,但未实现浅层与深层特征的融合传递,特征表达能力有限;与 ResNet 和 Darknet 相比,二者虽通过跳跃连接提升了特征丰富度,但未引入通道分离技术,无法实现特征的选择性传递;文中 FEM 模块优势在于综合 VGG 与 ResNet 的核心特性,通过 3×3 卷积层堆叠获取大感受野特征,借助跳跃连接实现深浅层特征融合,同时利用通道分离技术在精简参数量的前提下保障原始特征有效传递,实现了特征提取性能与模型轻量化的平衡。

1.2 MSPPF 模块

MSSPP 最先由 He 等^[12]提出,用来解决传统 CNN 对输入图像大小的限制,后经过改进在 YOLO 系列目标检测算法中用作多尺度特征的提取^[13]。文中所提的 MSPPF 模块也是受到空间金字塔池化快速模块(spatial pyramid pooling-fast, SPPF)的启发,其网络结构示意图如图 3 所示,MaxPool 为最大池化。

输入特征图首先经过卷积核为 3×3 ,步长为 2 的卷积进行特征图下采样,然后分为 3 个分支,第 1 分支保持特征不变直接传递至输出端;第 2 分支经池化核大小为 3×3 的最大池化处理后连接输出;第 3 分支依次经过 2 次池化核大小为 3×3 的最




图 3 MSPPF 模块结构示意图

Fig. 3 Schematic diagram of the MSPPF module

大池化操作后接入输出。将 3 路不同感受野的特征图拼接后,通过卷积核大小为 1×1 、步长为 1 的卷积操作进行通道降维,同时增强模型的非线性表达能力。现有多尺度池化模块常采用池化核尺寸为 5×5 、 9×9 、 13×13 的并行池化结构获取多尺度特征,而文中 MSPPF 模块未采用该方案,转而通过池化核尺寸为 5×5 的串行池化设计实现不同感受野特征的提取。该设计在显著降低计算复杂度的同时,可达到与并行池化结构相当的多尺度特征提取效果,实现了性能与效率的平衡。

1.3 CAM

注意力机制在各类 CNN 算法中广泛应用,旨在特征提取过程中聚焦关键颜色特征与几何结构信息,进而提升算法性能。例如:SeNet(squeeze-and-excitation networks)^[14]常用于图像分类任务;SAM(spatial attention module)^[15]则在目标检测领域得到广泛应用。为精准恢复水下图像的细节特征,文中所提增强网络在编码阶段嵌入 4 个 CAM,以强化模型对浅层边缘信息与纹理特征的提取能力,其具体结构示意图如图 4 所示。

由图 4 可以看出,特征图在经过最大池化后为 $1 \times 1 \times C$ 的特征图,考虑到全连接层会破坏空间结构,使用 1×1 的卷积来进行维度非线性映射,图中的 C/r 是指先将维度降为原来的 $1/4$, $r=4$,然后恢复原始通道数,最后与池化后的特征图相乘以实现 SeNet。在编码阶段每经过 1 个 FEM 就会使用 CAM 进行通道信息加强,这样不同尺度的特征都经过加强后在解码阶段浅层信息也能得到较好的保留,对于图像细节恢复有着关键作用。




图 4 CAM 模块具体结构示意图

Fig. 4 Detailed structure diagram of CAM module

1.4 损失函数设计

损失函数的设计对图像增强算法的性能至关重要,不同类型的损失函数适用于不同任务场景^[16]。目前主流损失函数中, L_1 损失、 L_2 损失常用于回归任务与图像增强任务,交叉熵损失则主要应用于分类任务。 L_1 损失函数表达式为

$$L_1 = \frac{1}{N} \sum |y - y_{\text{pre}}| \quad (1)$$

式中: y 为真实值; y_{pre} 为预测值; N 为样本数量。

由式(1)可知, L_1 损失函数的核心用于衡量模型预测值与真实值之间的像素级差异,但未充分考虑图像的结构一致性、色彩保真度等对人眼视觉感知至关重要的信息^[17]。为此,文中在损失函数设计中引入 SSIM 损失以弥补该缺陷,计算公式为

$$(x, y)_{\text{SSIM}} = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)} \quad (2)$$

式中: μ_x 为图像 x 的像素平均值; μ_y 为图像 y 的像素平均值; σ_{xy} 为图像 x 和 y 的协方差; σ_x^2 为图像 x 的方差; σ_y^2 为图像 y 的方差; c_1 和 c_2 为常数。

SSIM 从亮度、对比度和结构 3 方面反应图像的相似性,将其作为损失函数部分时,通过式(3)构建损失项

$$L_{\text{SSIM}} = 1 - (x, y)_{\text{SSIM}} \quad (3)$$

总损失函数为

$$L = k_1 L_1 + k_2 L_{\text{SSIM}} \quad (4)$$

式中, k_1 、 k_2 为权重系数。

L_1 损失与 SSIM 损失分别属于像素级和结构级的确定性度量方式,能够降低对抗损失中判别

器-生成器对抗训练所带来的振荡或梯度消失风险。其中, L_1 损失直接约束低频域的亮度及颜色信息,SSIM 损失则用于度量局部结构相似性,防止图像过度平滑。因此,文中采用 L_1 损失与 SSIM 损失的加权组合作为算法模型的损失函数。

2 算法实现

2.1 数据集构建

文中使用的图像数据集为大规模水下图像 (large scale underwater image dataset, LSUI)数据集,其中包含 4 279 对图像数据,整个数据集包含图像颜色失真、细节丢失以及图像整体呈现偏向绿色或蓝色等情况。在实验过程中,对数据集采用随机抽取的方式,按照 8:1:1 的比例划分为训练集、验证集和测试集。

2.2 评价指标

图像增强领域常用的树算法评价指标是 SSIM 和峰值信噪比 (peak signal-to-noise ratio, PSNR),水下图像增强的评价指标为水下图像质量度量 (underwater image quality measure, UIQM) 和水下彩色图像质量评估 (underwater color image quality evaluation, UCIQE)^[18]。其中, PSNR 与 SSIM 均为有参考图像质量评价指标,需依赖真实参考图像完成计算; UIQM 与 UCIQE 则属于无参考图像质量评价指标,无需参考图像即可实现质量评估。具体而言, UIQM 从色彩、清晰度及对比度 3 方面评价水下图像质量, UCIQE 则从色度、饱和度及对比度 3 方面进行评估,二者的计算公式如下

$$U_{\text{UIQM}} = a_1 U_{\text{UICM}} + a_2 U_{\text{UISM}} + a_3 U_{\text{UICONM}} \quad (5)$$

式中: U_{UICM} 代表色彩测量指标; U_{UISM} 代表清晰度测量指标; U_{UICONM} 代表对比度测量指标, a_1 、 a_2 和 a_3 为权重系数,分别取值为 0.15、0.25 和 0.6。

$$U_{\text{UCIQE}} = b_1 \sigma_c + b_2 \text{con}_l + b_3 \mu_c \quad (6)$$

式中: σ_c 代表色度标准差; con_l 代表亮度对比度; μ_c 代表饱和度平均值; b_1 、 b_2 和 b_3 为权重系数,分别取值为 0.468、0.274 5 和 0.257 6。

2.3 模型训练

文中训练模型的系统为 Ubuntu18.04,使用 pytorch2.0 开源深度学习框架,软件环境为 python 3.12、CUDA12.2 及 CuDnn v8.9,显卡为 NVIDIA

GeForce RTX4090。文中所提算法训练过程设置的部分网络参数如表 1 所示。

表 1 网络参数配置表

Table 1 Network parameter configuration table

参数	值
输入尺寸	256×256
学习率	0.001
批大小	64
权重衰减	0.000 5
动量	0.937

2.4 模型部署

为减少数据传输时延、降低带宽压力,可在边缘端完成数据处理(即边缘计算)。通过在传感器端搭载 AI 加速芯片(如海思 3559A、瑞芯微 RK3588 及华为 Atlas200I A2 等),可实现采集图像数据的实时处理。文中设计的算法已分别部署于瑞芯微 RK3588 与华为 Atlas 200I A2 平台,2 款芯片核心参数如下。

1) 瑞芯微 RK3588: 支持 INT4、INT8、INT16 及 FP16 等多种运算模式,算力达 6 TOPS(tera operations per second); 采用电子产品处理器架构 ARM (acorn risc machine), 内置 8 个处理核包括 4 个 Cortex-A76 大核和 4 个 Cortex-A55 小核,大核最高主频 2.4 GHz,小核具备低功耗特性,适配低负载场景,可通过任务绑定不同核心实现性能与能效的平衡。

2) 华为 Atlas200I A2: 搭载昇腾 310 AI 处理器,集成 2 个 DaVinci AI Core 与 4 核 Taishan V200M 处理器(主频 1.6 GHz),算力高达 20 TOPS。

深度学习算法在 AI 芯片上的部署流程为: 服务器端完成算法设计与网络模型训练—将模型导出为开放神经网络交换格式(open neural network exchange, ONNX)格式—转换为 AI 芯片适配格式—撰写 C++工程(包含模型初始化、数据预处理、前向推理及后处理等步骤)。文中所提算法在 Atlas 200I A2 平台上的运行流程如图 5 所示。

将算法模型转换为 ONNX 模型后,需要通过 ONNXruntime 库进行 ONNX 模型前向推理结果的比对,确保与 pytorch 模型输出的结果保持一致。然后将 ONNX 模型通过 Ascend Tensor Compiler 模型转换工具,进行浮点(floating-point, FP)16 与




图 5 算法流程图

Fig. 5 Flow chart of the algorithm

FP32 的混合精度量化,这种量化方式可以减少模型量化造成的精度损失,在增加少量耗时的前提下保持算法的性能,文中所提算法在不同平台部署前向推理的耗时如表 2 所示。

表 2 不同平台推理耗时

Table 2 inference time on different platforms

平台	FP16/ms	FP16&FP32/ms
RK3588	42	58
Atlas 200I A2	28	31

由表 2 数据可知,Atlas200I A2 平台算力更强、实时性更优,可满足 30 帧/s 的工程应用要求。传统图像增强算法计算复杂度高,需依赖 Eigen、开源计算机视觉库(open source-computer vision library, Open-CV)等工具进行矩阵加速,且对 CPU 占用率较高,易影响其他软件应用运行;深度学习原生模型则参数量大,仿真阶段为提升性能常设计复杂模块,而现有边缘计算平台受算力限制、算子支持度不足等影响,许多性能优异的算法难以移植部署。相比之下,文中所提算法在边缘端部署具备显著优势,其网络架构仅选用卷积、池化及 Concat 等常规算子,且通过轻量化设计大幅精简模型参数量,在保证良好图像增强效果的同时,具备更强的移植性,可适配主流边缘计算平台。

3 实验与分析

为了证明文中所提算法的有效性和泛化性,实验选取主流增强算法作为对比,在水下图像增强领域(realworld-underwater-image-enhancement, RUIE)数据集上开展对比实验,并从定性与定量 2 个方面

分析验证算法的有效性。

3.1 实验结果

为验证文中所提算法的先进性, 选取 6 种常用增强算法开展对比实验, 包括限制对比度自适应直方图均衡(contrast limited adaptive histogram equalization, CLAHE)^[19]、集成颜色模型(integrated color model, ICM)^[20]、快速水下图像增强生成对抗网络(fast underwater image enhancement GAN, FUnIE-GAN)^[21]、基于物理模型的神经网络(physical neural network, PhysicalNN)^[22]、Retinex^[23]以及用于水下图像增强的压缩模型 Shallow^[24]。LSUI 测试集上的增强结果如图 6 所示。可见文中算法相比原始图像, 不仅显著提升了图像清晰度与对比度, 还有

效恢复了颜色信息——原始图像因红光被吸收常出现整体偏蓝或偏黄的问题, 经文中算法处理后颜色更贴近真实场景, 视觉体验大幅优化, 图像整体质量得到明显提升。由图 6 可知, 传统算法 CLAHE 及 ICM 的增强效果明显逊于深度学习算法, 其处理后的图像仍存在显著色偏; FUnIE-GAN 算法的颜色恢复效果优于传统算法, 但仍存在一定色差; PhysicalNN 算法在颜色恢复与清晰度提升方面均表现更佳, 不过视觉效果仍不及文中所提算法。综合对比来看, 文中算法处理后的图像对比度更高且色彩分布更均匀, 目标物体轮廓更清晰, 整体视觉效果最优。




图 6 LSUI 数据集增强结果对比

Fig. 6 Comparison of enhancement results on the LSUI dataset

为了进一步验证文中所提算法的泛化性, 在水下图像增强基准(underwater image enhancement benchmark, UIEB)数据集上也做了增强测试, 其结果如图 7 所示。

由实验结果可以看到, Retinex 算法通过分离反射光和环境光成分别进行处理后得到增强后的图像, 可以一定程度恢复图像颜色, 提升暗部细节; Shallow 算法在颜色恢复和细节提升表现一般; 文中所提算法在以上几种算法中颜色恢复效果最好, 增强后的图像目标清晰度更高。

3.2 实验分析

上文只是定性分析了文中所提算法的先进性, 还需利用水下图像质量评价指标定量计算验证文中算法性能的优势。上述几种算法在 LSUI 数据集中 428 张测试集图像上的各相关指标统计结果如表 3 所示。

实验数据显示, 文中所提算法的 UIQM 与 UCIQE 指标均为最高, 相比传统算法 CLAHE 分别提升 1.29 和 0.04, 相比 PhysicalNN 分别提升 0.02 和 0.09。其性能优势源于多维度设计优化: 一是采




图 7 UIEB 数据集增强结果对比

Fig. 7 Comparison of enhancement results on the UIEB dataset

表 3 不同算法测试指标

Table 3 Test indicators of different algorithms

算法	UIQM	UCIQE	PSNR	SSIM
CLAHE	3.95	0.59	16.67	0.59
ICM	3.22	0.48	15.84	0.53
FUnIE-GAN	3.87	0.50	18.28	0.64
PhysicalNN	4.31	0.54	21.25	0.72
Retinex	4.08	0.53	19.75	0.61
Shallow	4.02	0.49	18.05	0.65
文中	4.33	0.63	25.84	0.87

用 U-Net 网络结构结合 CAM 模块,有效挖掘并利用浅层几何与颜色信息,显著增强了色彩失真修正与纹理细节恢复能力;二是在主干网络中嵌入 MSPPF 模块,通过多尺度特征提取丰富特征表达维度,对提升图像全局对比度起到关键性支撑作用;三是在损失函数中引入 SSIM 项,引导模型重点学习目标图像的结构信息,进一步优化增强后图像的视觉自然度。综上,文中算法通过 FEM、MSPPF 与 CAM 的高效融合,搭配损失函数改进及网络轻量化设计,实现了“增强效果优”与“边缘部署快”的双重优势,兼顾性能与实时性需求。

4 结束语

针对水下可见光图像因水体散射与吸收导致的噪声干扰、纹理模糊及颜色失真等问题,文中提出一种基于多尺度 CNN 的水下图像增强算法。该算法通过 U-Net 结构融合浅层纹理特征与深层语

义特征,在主干网络中引入多尺度金字塔池化模块提取多尺度特征,并嵌入 SSIM 损失函数,有效改善图像颜色与细节的恢复效果。为推动算法落地实际工程应用,将其量化后部署于嵌入式平台实现边缘端实时处理,可显著降低边缘端数据处理单元的计算压力,降低对高性能处理器的依赖。实验表明,文中增强算法的图像质量评价指标优于对比算法,且在 Atlas 200I A2 平台上可实现实时图像增强;但在复杂水下场景的增强效果仍有提升空间,后续将进一步改进算法以提升增强效果与环境适应性,并深入研究算法在嵌入式平台的加速计算策略。

参考文献:

[1] 王永鑫,刁鸣,韩闯. 基于同态滤波的水下图像增强与色彩校正模型[J]. 计算机工程与应用, 2018, 54(11): 30-34.
WANG Y X, DIAO M, HAN C. Underwater image enhancement and color correction model based on homomorphic filtering[J]. Computer Engineering and Applications, 2018, 54(11): 30-34.

[2] 李黎,王惠刚,刘星. 基于改进暗原色先验和颜色校正的水下图像增强[J]. 光学学报, 2017, 37(12): 9.
LI L, WANG H G, LIU X. Underwater image enhancement based on improved dark primary prior and color correction[J]. Acta Optica Sinica, 2017, 37(12): 9.

[3] 杨润,刘增力,赵宣植. 基于颜色校正和暗亮双通道先验的水下图像增强算法[J]. 红外技术, 2024, 46(9): 984-993.
YANG R, LIU Z L, ZHAO X Z. Underwater image enhancement algorithm based on color correction and dual

- channel prior of brightness and darkness[J]. *Infrared Technology*, 2024, 46(9): 984-993.
- [4] 王燕, 张金峰, 王丽康, 等. 基于注意力机制与特征重建的水下图像增强[J]. *红外技术*, 2024, 46(9): 1006-1014.
- WANG Y, ZHANG J F, WANG L K, et al. Underwater image enhancement based on attention mechanism and feature reconstruction[J]. *Infrared Technology*, 2024, 46(9): 1006-1014.
- [5] 程竹明, 李佳轩, 黄三傲, 等. 基于多分支残差注意力网络的水下图像增强[J]. *光学精密工程*, 2025, 33(7): 1141-1151.
- CHENG Z M, LI J X, HUANG S A, et al. Underwater image enhancement based on multi branch residual attention network[J]. *Optical Precision Engineering*, 2025, 33(7): 1141-1151.
- [6] 王树林, 杨建民, 卢昌宇, 等. 一种基于双通道的水下图像增强卷积神经网络[J]. *海洋工程*, 2023, 41(6): 158-170.
- WANG S L, YANG J M, LU C Y, et al. A dual channel underwater image enhancement convolutional neural network[J]. *Ocean Engineering*, 2023, 41(6): 158-170.
- [7] 严浙平, 曲思瑜, 邢文. 水下图像增强方法研究综述[J]. *智能系统学报*, 2022, 17(5): 860-873.
- YAN Z P, QU S Y, XING W. A review of underwater image enhancement methods[J]. *Journal of Intelligent Systems*, 2022, 17(5): 860-873.
- [8] MAGGIORI E, TARABALKA Y, CHARPIAT G, et al. Convolutional neural networks for large-scale remote-sensing image classification[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2016, 55(2): 645-657.
- [9] WU Z, SHEN C, VAN DEN HENGEL A. Wider or deeper: Revisiting the resnet model for visual recognition[J]. *Pattern Recognition*, 2019, 90: 119-133.
- [10] CHEN R C. Automatic license plate recognition via sliding-window darknet-YOLO deep learning[J]. *Image and Vision Computing*, 2019, 87: 47-56.
- [11] ZHAO C, CHEN M. YOLOv7-RFCW of a lightweight target detection algorithm for benthic organisms underwater[J]. *Transactions of the Chinese Society of Agricultural Engineering*, 2024, 40(11): 168-177.
- [12] HE K, ZHANG X, REN S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, 37(9): 1904-1916.
- [13] XU C, DU Y, ZHENG W, et al. Facial expression recognition based on YOLOv8 deep learning in complex scenes[J]. *International Journal of Information and Communication Technology*, 2025, 26(1): 89-101.
- [14] HU J, SHEN L, SUN G, et al. Squeeze-and-excitation networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017: 7132-7141.
- [15] ZHAO D, LIU K, ZHANG Z, et al. Efficient stereo matching using attention mechanism and edge optimization[J]. *Journal of Electronic Imaging*, 2023, 32(5): 16.
- [16] 黄巧玲, 郑伯川, 丁梓成, 等. 融合监督注意力模块和跨阶段特征融合的图像修复改进网络[J]. *计算机应用*, 2024, 44(2): 572-579.
- HUANG Q L, ZHENG B C, DING Z C, et al. Improved image restoration network integrating supervised attention module and cross stage feature fusion[J]. *Computer Applications*, 2024, 44(2): 572-579.
- [17] ZHANG W D, ZHUANG P X, SUN H H, et al. Underwater image enhancement via minimal color loss and locally adaptive contrast[J]. *IEEE Transactions on Image Processing*, 2022, 31: 3997-4010.
- [18] SINGH N, BHAT A. A robust model for improving the quality of underwater images using enhancement techniques[J]. *Multimedia tools and Applications*, 2024(1): 83.
- [19] 朱恒军, 王天落, 马利浩. 水下图像的颜色校正及对比度增强算法研究[J]. *舰船电子工程*, 2023, 43(8): 149-154.
- ZHU H J, WANG T L, MA L H. Research on color correction and contrast enhancement algorithms for underwater images[J]. *Ship Electronic Engineering*, 2023, 43(8): 149-154.
- [20] KASHIF I, SALAM R A, AZAM O, et al. Underwater image enhancement using an integrated colour model[J]. *International Journal of Computer Science*, 2007, 34(2): 239-244.
- [21] TSAI Y S, CHANG K W, LAN Y J. Advancing underwater image clarity: A GAN-based approach with residual blocks and linear blending[J]. *Machine Vision and Applications*, 2025, 36(4): 1-22.
- [22] 陈学磊, 张品, 权令伟, 等. 融合深度学习与成像模型的水下图像增强算法[J]. *计算机工程*, 2022, 48(2): 243-249.
- CHEN X L, ZHANG P, QUAN L W, et al. Underwater image enhancement algorithm integrating deep learning and imaging models[J]. *Computer Engineering*, 2022, 48(2): 243-249.
- [23] ZHUANG P X, WU J M, PORIKL F, et al. Underwater image enhancement with Hyper-Laplacian reflectance priors[J]. *IEEE Transactions on Image Processing*, 2022, 31: 5442-5455.
- [24] NAIK A, SWARNAKAR A, MITTAL K. Shallow-UWnet: Compressed model for underwater image enhancement(student abstract)[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Vancouver, USA: AAAI, 2021, 35(18): 15853-15854.

(责任编辑: 闫溶蔓)